

Optimizing Matching Markets: A Comprehensive Approach Using Graph Neural Networks and Reinforcement Learning

(マッチング市場の最適化: グラフニューラルネットワークと
強化学習を用いた包括的なアプローチ)


2024年2月1日

電子情報学専攻 鈴木研究室

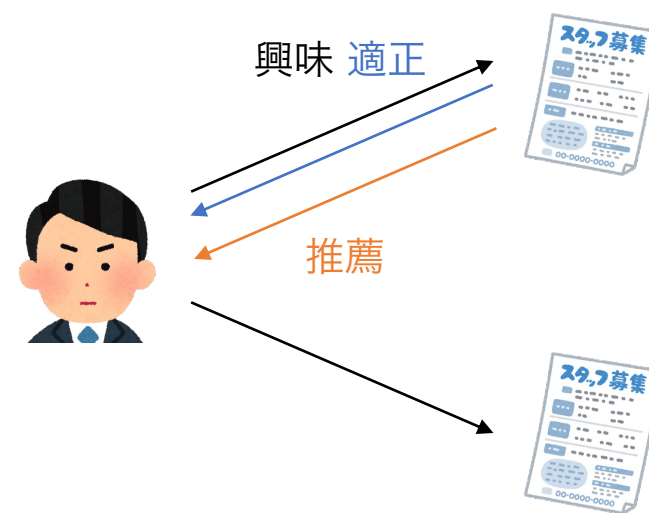
修士2年 48-226456 脇 聡志

1. 背景：ジョブ推薦システムでの相互推薦

- ジョブ推薦システムとは「求職者」に「求人」を推薦するシステム
- システムの最終目標は「**マッチング**（求職者の採用）」を達成すること
- 求職者の嗜好だけでなく、雇用者のニーズも考慮した「**相互推薦**」が必要




従来の**一方向**の推薦システム
クリック/購入が最終目標



双方向の相互推薦システム
マッチングが最終目標

1. 背景：従来のジョブ推薦システムの限界

- 既存の研究では**短期的**で、**個別最適化**された推薦をしている
- 現在推薦している求職者が最もマッチングしやすい求人を推薦
 - 新たに追加された求人の推薦が軽視される可能性がある
- 現在推薦している求職者のみの情報に基づいて推薦
 - より適格な他の求職者から既に応募されている求人を推薦する可能性がある
 - 人気の求人を全求職者に推薦する可能性がある



上の求職者に推薦する求人を決める際には

- その求人に既に応募している求職者の情報
- 今後、応募しそうな求職者の情報
- その求人の人気さ

など**長期的**で、**市場全体**の情報を加味しなければならない

1. 背景：本研究の目的と貢献

目的： **長期的**で、 **市場全体**の情報を加味したジョブ推薦システムの研究

具体的には主に2つのアプローチを試みた（薄字は発表では省略）：

1. 長期的な最適化のため **強化学習（RL）** を導入

- ジョブマッチングをマルコフ決定過程（MDP）として定式化
- 強化学習手法のREINFORCEとActor-Criticを適用

2. 市場全体の最適化のため **グラフニューラルネットワーク（GNN）** を導入

- GNN手法のRelational Graph Convolutional Network（R-GCN）を適用
- ラベル付きのエッジを追加する **新しいグラフデータ拡張（GDA）** の手法を提案
- 提案手法の有効性を実世界のデータおよび合成データを用いたシミュレーションで検証

2. 関連研究：LiJAR [Borisyyuk et al., 2017]

- 求人が得る**応募数が均等**になるように推薦を調整する手法

➤以下の2つの値を予測するモデルを学習

- ある求職者が求人に応募する確率(*originalScore*)
- 求人締め切り時の応募数(*#applications*)

➤以下の式からスコアを調整して応募数が均等になるよう調整

$$\text{Penalization : } newScore = originalScore \cdot e^{-\frac{\#applications}{softness}}$$

$$\text{Boosting : } newScore = \min\{originalScore \cdot boostFactor, 1.0\}$$

- 課題点：

- どれくらい応募数をバランスするかはハイパーパラメータに大きく依存
- 目標が応募数の均等化であり、マッチング数の最大化ではない

2. 関連研究：安定マッチング

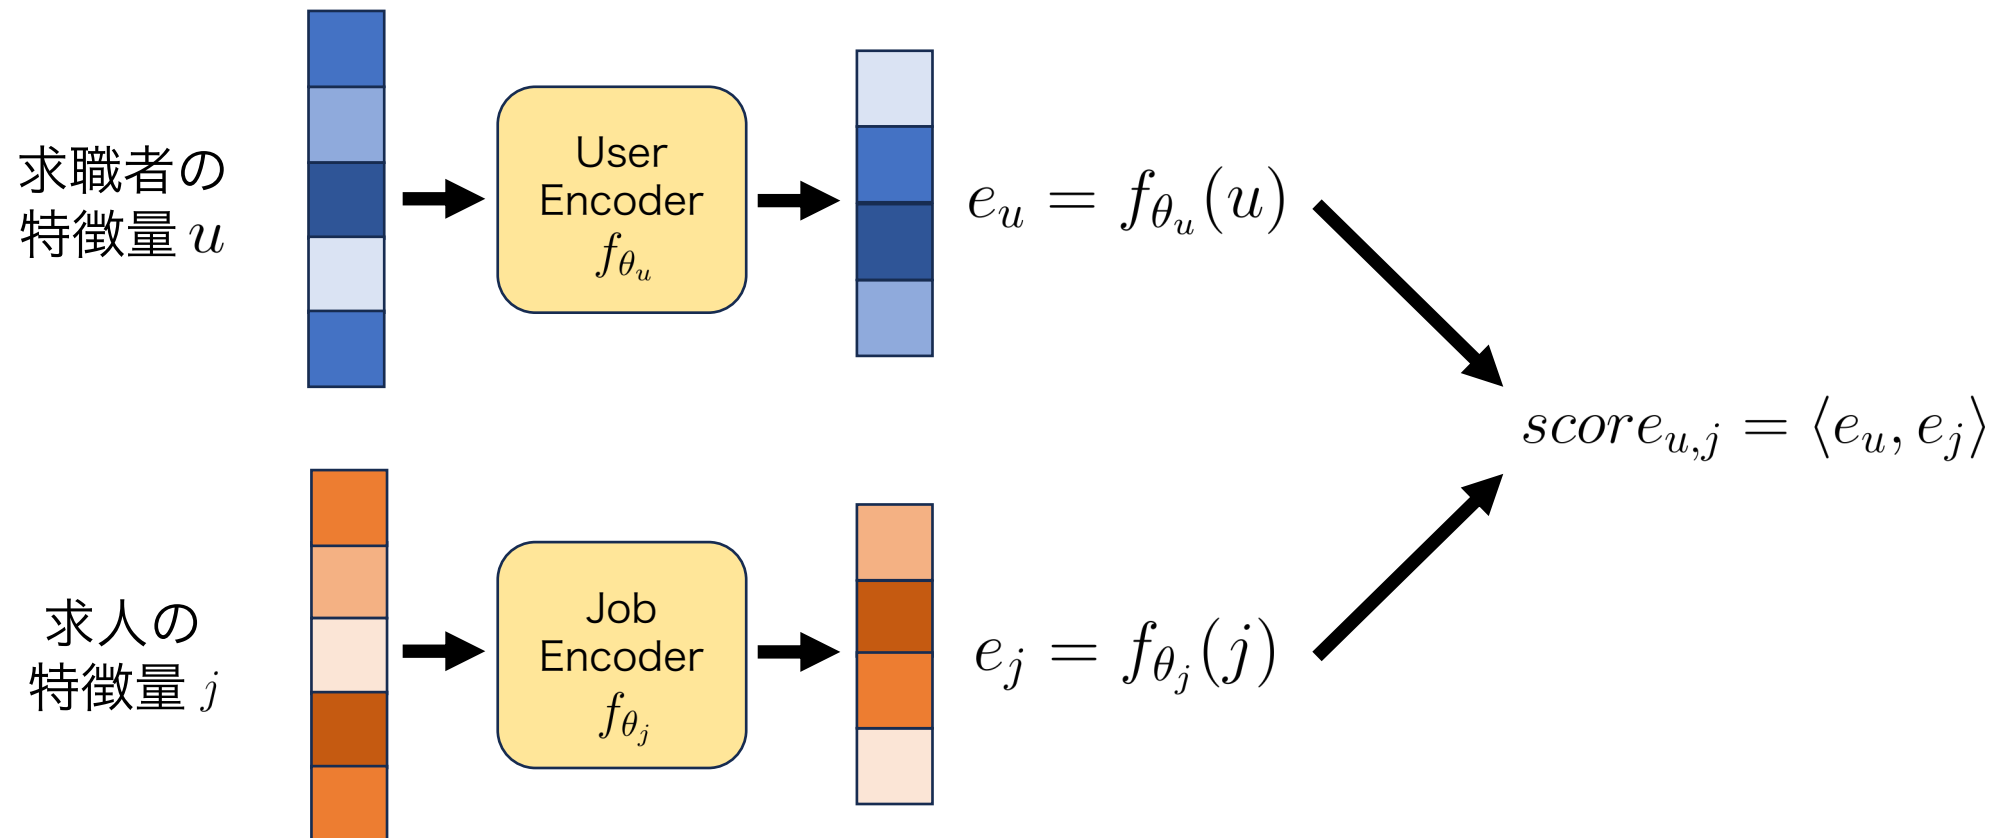
- 安定マッチングに基づいて推薦する手法
 - 「互いに現在組んでいる相手よりも好きであるペアが存在しないようなマッチング」
 - TomitaらはTUマッチングを用いてOnline Datingで安定マッチングを求めた
- 課題点
 - すべてのペアに対して希望順序が分かっていることが前提
 - 一対一のマッチングを求める手法が殆どで、ジョブ推薦システムには向かない
 - 「安定性」を測るのが難しく、結局多くの研究が「マッチング総数」で性能を評価

2. 関連研究：既存研究 vs. 提案手法

手法	互惠性 (双方向性)	長期最適化	全体最適化	多様な関係性の考慮
従来の（一方向の） 推薦システム	×	△ (RLを適用した推薦システム に適用した研究はある)	×	○
従来の 相互推薦システム	○	×	×	×
LiJAR	○	×	△ (応募数に関して全体で 均等になるよう推薦)	×
安定マッチング	○	×	○	×
提案手法	○	○	○	○


3. 提案手法：Two-Tower Modelsの導入

- Two-Tower Modelsは推薦システムでよく適用される最もシンプルなモデル
- Two-Tower Modelsでは求職者の特徴量を埋め込むエンコードと、求人の特徴量を埋め込むエンコードの2つを用意し、そのコサイン類似度や内積を推薦確率とする



3. 提案手法： R-GCNの導入

- Two-Tower Modelsでは市場全体の情報を埋め込めない
- 求職者と求人の二部グラフを構築して、GNNで特徴量を埋め込む
- GNNはエッジ経由でノードの情報を伝搬させることで、周辺情報を埋め込む
- GNN手法の一つであるRelational Graph Convolutional Network (R-GCN) を適用
- R-GCNでは、ラベル付きのエッジをもつグラフを扱える



3. 提案手法：新しいグラフデータ拡張（GDA）の提案

- 応募やマッチに関する相互作用は一般的に極端に少なく、十分に情報が伝搬されない
- ラベル付きのエッジを追加するグラフデータ拡張を提案

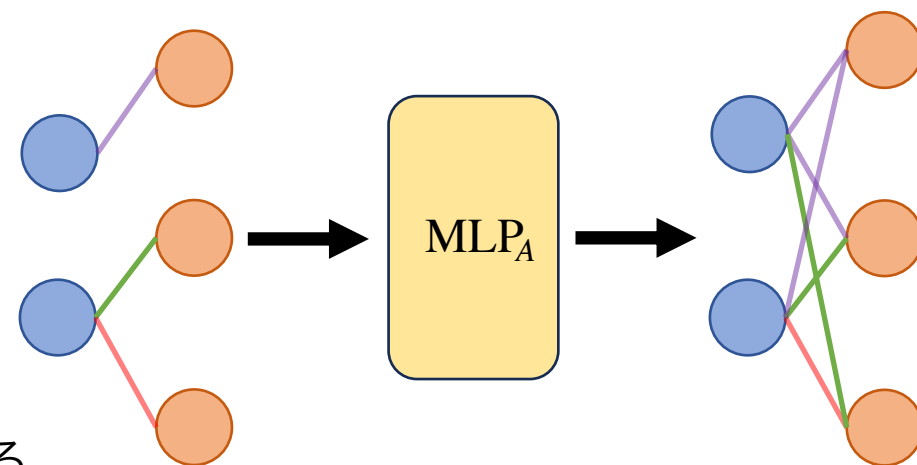
- 従来の手法はすべて、単一タイプのエッジを追加するのみ
- Two-Tower Modelsで計算した埋め込み e_u, e_j 、及びエッジのone-hotベクトル e_r からエッジの追加確率を計算：

$$p_{u,j} = \sigma(\text{MLP}_A(e_u \parallel e_j \parallel e_r))$$

- MLPの出力を多次元にする事でラベル付きのエッジを追加
- $p_{u,j}$ の \tilde{r} 番目から新しいラベル \tilde{r} に対する隣接行列を得る：

$$A_{u,j}^{(\tilde{r})} \sim \text{Bernoulli}(p_{u,j}^{(\tilde{r})})$$

- Gumbel-Softmax reparameterization trickで微分可能にする



3. 提案手法： Actor-Criticの導入

- 長期的な最適化を行うために強化学習手法のActor-Criticを導入
- 強化学習では将来の報酬を加味した累積報酬を最大化させるようにモデルを学習

$$V := \sum_{t=0}^{\infty} \gamma^t r_t$$

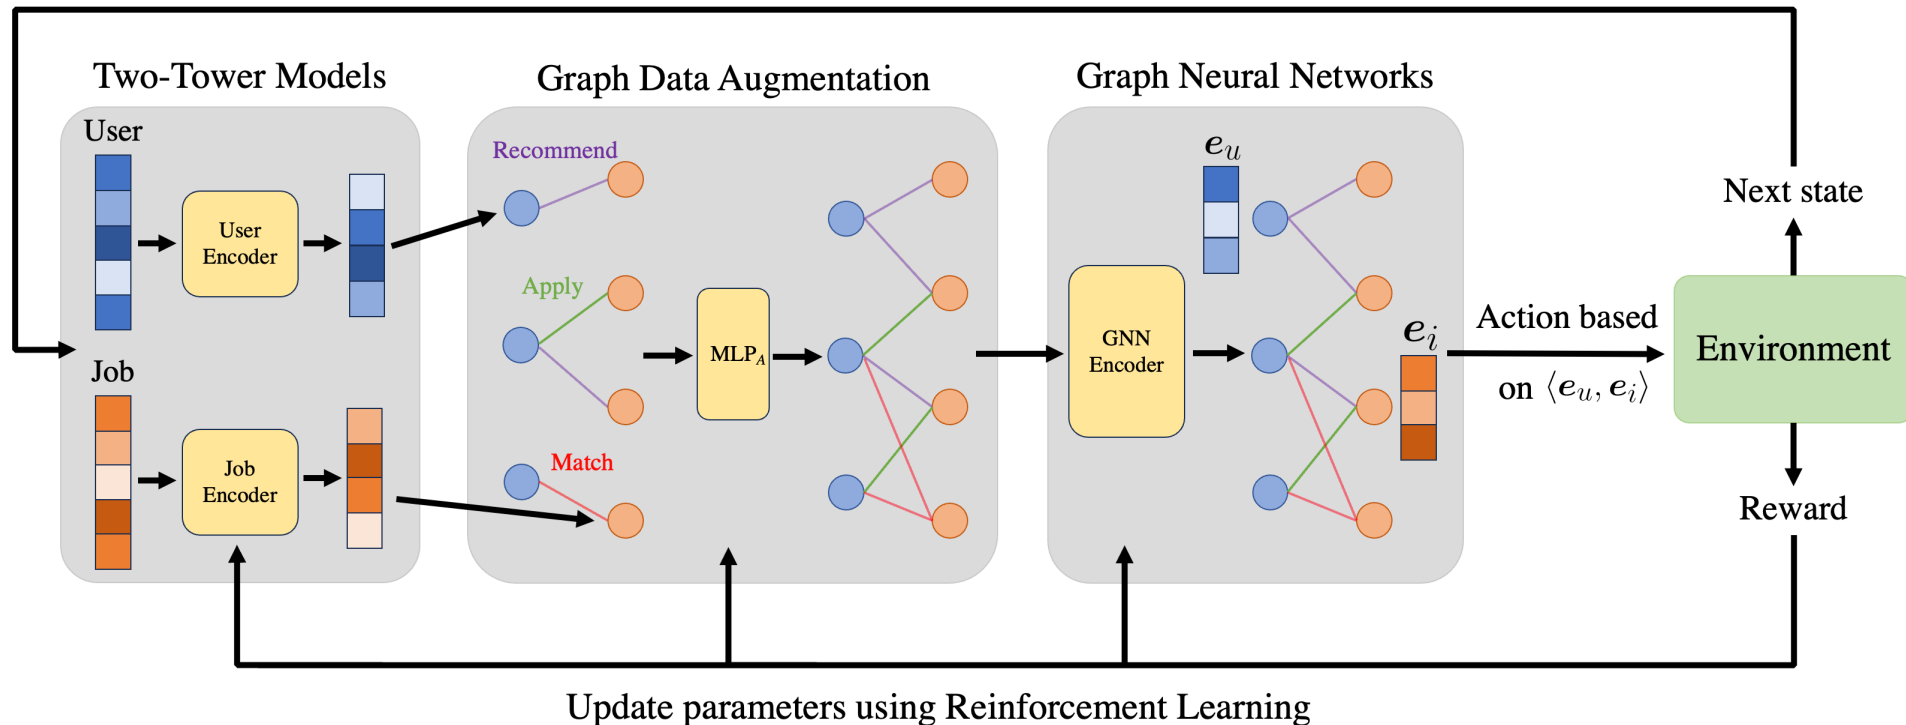
- Actor-Criticでは以下のように勾配を計算してパラメータを学習

$$\begin{aligned} J(\theta) &= \nabla_{\theta} \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r_t \mid \pi_{\theta} \right] \\ &\simeq \sum_{t=0}^{\infty} \nabla_{\theta} \log \pi_{\theta}(a_t \mid s_t) (r_t + \gamma V_{\omega}(s_{t+1}) - V_{\omega}(s_t)) \end{aligned}$$

ただし $V_{\omega}(s_t)$ は状態価値関数であり、 $V_{\omega}(s_t)$ が $r_t + \gamma V_{\omega}(s_t)$ を推定するよう訓練

3. 提案手法： 提案手法の全体像

- まず、Two-Tower Modelsで求職者と求人の特徴量を同じ次元に埋め込む
- 次に我々のGDA手法により、ラベル付きのエッジを再構成する
- R-GCNを用いることで市場全体の情報を加味した埋め込みを行う
- 最後に報酬（マッチング総数）に基づいて、Actor-Criticによりこれらすべてのモデルを学習する



4. 実験： 実験設定

- 実世界のデータ及び合成データを用いたシミュレーションにより評価
 - 実データは、株式会社エス・エム・エスより提供して頂いたプライベートデータSMSとKaggleで公開されているCareerBuilder2012を使用
 - 合成データは、応募に関する人気の分布が変化するように5つのデータを生成し使用

	SMS	CareerBuilder2012	Synthetic 1	Synthetic 2	Synthetic 3	Synthetic 4	Synthetic 5
<i>imbW</i>	-	-	0.1	1.0	1.0	1.0	2.0
<i>imbLen</i>	-	-	100	50	100	150	100
#Users	300	300	300	300	300	300	300
#Jobs	300	300	300	300	300	300	300
#Applications	36,746	25,873	34,697	39,176	44,894	51,017	49,694
#Matchings	14,784	3,776	4,359	8,682	13,623	19,004	22,119
Maximum #Matchings	126	101	115	134	126	184	173
Apply Gini Coefficient	0.23	0.27	0.41	0.40	0.36	0.31	0.35
Match Gini Coefficient	0.70	0.74	0.79	0.80	0.75	0.68	0.71

4. 実験： 比較手法

- ApplyPredictor :
 - Two-Tower Modelsで応募確率を学習し、そのスコアに基づき推薦
 - 従来の（一方向の）推薦システム
- MatchPredictor :
 - Two-Tower Modelsでマッチ確率を学習し、そのスコアに基づき推薦
 - 一般的な双方向の相互推薦システム
- LiJAR :
 - Two-Tower Modelsで応募確率を学習し、応募数が均等になるようスコアを調整し推薦
 - 詳細は関連研究
- StableMatching :
 - 2つのTwo-Tower Modelsで応募確率とマッチ確率を学習し、各ペアの希望順序を計算
 - 求めた希望順序からGale-Shapleyアルゴリズムで安定マッチングを求める手法

4. 実験： マッチング総数に関する結果

- すべての環境において、提案手法が最もよい性能を示した
- 'Ours w/o GDA'とOursを比べることで、 GDAが性能向上に寄与していると分かる
- 'Ours w/o GDA'と'Ours w/o GNNs'を比べると、 GNNsが性能向上に寄与していると分かる
- 'Ours w/o GNNs'とMatchPredictorを比べると、 RLが性能向上に寄与していると分かる

	SMS	CareerBuilder2012	Synthetic 1	Synthetic 2	Synthetic 3	Synthetic 4	Synthetic 5
ApplyPredictor	0.00 ± 0.00	0.00 ± 0.00	1.00 ± 0.00	1.00 ± 0.00	1.00 ± 0.00	1.00 ± 0.00	1.00 ± 0.00
MatchPredictor	0.00 ± 0.00	0.00 ± 0.00	0.33 ± 0.47	0.33 ± 0.47	0.00 ± 0.00	0.00 ± 0.00	5.00 ± 0.00
LiJAR	1.33 ± 0.47	0.00 ± 0.00	5.00 ± 0.00	5.00 ± 0.00	8.00 ± 0.00	16.67 ± 0.47	20.33 ± 0.94
StableMatching	18.00 ± 2.94	4.33 ± 1.25	3.33 ± 1.25	9.00 ± 0.00	11.33 ± 4.11	16.33 ± 1.70	20.67 ± 3.86
Ours w/o GNNs	1.00 ± 0.00	5.33 ± 1.89	4.33 ± 1.89	15.67 ± 0.47	26.00 ± 0.00	28.67 ± 0.47	55.33 ± 1.25
Ours w/o GDA	<u>19.33 ± 1.70</u>	<u>6.00 ± 0.00</u>	<u>13.00 ± 1.41</u>	<u>18.33 ± 3.68</u>	<u>31.33 ± 3.40</u>	<u>37.67 ± 0.47</u>	<u>64.00 ± 1.41</u>
Ours	23.00 ± 3.56	10.00 ± 2.94	23.33 ± 2.87	31.67 ± 4.99	50.67 ± 1.89	62.33 ± 3.09	71.67 ± 1.70

5. まとめと今後の課題

- まとめ

- ジョブ推薦システムにおいて長期的で市場全体の最適化を行うシステムを目標に研究
- 強化学習、GNN、グラフデータ拡張を組み合わせた新しい手法を提案
- ラベル付きのエッジを追加する新しいグラフデータ拡張手法の提案
- 実世界のデータ及び合成データによる実験により有効性を確認

- 今後の課題

- Actor-CriticやR-GCNをより性能の良い最先端の手法に置き換え
- 求職者のログイン率や求人の締切が違うなどシミュレーション環境（MDP）をより現実的な設定に改良して実験・オンラインA/B実験で評価
- 社会実装に向けた、スケーラビリティや推定時間に関する改善
- ジョブマッチング以外のマッチング市場におけるデータセットで検証

6. 謝辞

- This work is supported by "Joint Usage/Research Center for Interdisciplinary Large-scale Information Infrastructures (JHPCN)" and "High Performance Computing Infrastructure (HPCI)" in Japan (Project ID: jh221002).
- In addition, this work was supported by JSPS KAKENHI Grant Numbers JP21K17749, JP21K21280, JP23H03408, JP22K17899.
- We would also like to express our sincere gratitude to SMS Co., Ltd. (SMS) for providing the data essential for our study.

7. 对外発表

- 脇 聡志, 鈴木 豊太郎, 金刺 宏樹, 華井 雅俊 and 小林 秀. 強化学習によるマッチング数を最大化するジョブ推薦システム. 2023年度人工知能学会全国大会. 2023.
- Satoshi Waki, Toyotaro Suzumura, and Hiroki Kanezashi. Optimizing Matching Markets with Graph Neural Networks and Reinforcement Learning. AAAI-24 Workshop on Recommendation Ecosystems. 2024.
- Satoshi Waki and Toyotaro Suzumura. Reciprocal Recommendation with Reinforcement Learning and Graph Neural Networks. In the Proceedings of the The 47th International ACM SIGIR Conference on Research and Development in Information Retrieval. (Submitted)

補足資料（その他の指標での評価）

Table 4: Comparisons between our method and baselines on the final total number of applications. Results that indicate the highest values are shown in bold, and the second-highest values are underlined.


	Private Data	CareerBuilder2012	Synthetic 1	Synthetic 2	Synthetic 3	Synthetic 4	Synthetic 5
ApplyPredictor	25.33 \pm 3.09	12.33 \pm 2.49	<u>68.00</u> \pm 2.16	99.00 \pm 0.82	99.00 \pm 0.82	99.00 \pm 0.82	100.00 \pm 0.00
MatchPredictor	33.33 \pm 5.19	7.67 \pm 1.70	12.00 \pm 2.94	35.67 \pm 6.55	5.00 \pm 0.82	24.67 \pm 4.50	<u>97.00</u> \pm 0.82
LiJAR	23.00 \pm 4.08	17.33 \pm 6.55	44.67 \pm 0.47	<u>96.67</u> \pm 1.25	<u>97.33</u> \pm 0.47	<u>98.00</u> \pm 0.82	100.00 \pm 0.00
StableMatching	<u>40.33</u> \pm 1.70	<u>25.33</u> \pm 4.19	30.67 \pm 2.87	36.67 \pm 3.68	38.00 \pm 2.94	48.00 \pm 2.83	47.33 \pm 3.68
Ours w/o GNNs	34.33 \pm 3.40	26.67 \pm 1.25	47.67 \pm 4.99	54.00 \pm 0.82	49.33 \pm 8.01	64.00 \pm 5.89	82.67 \pm 0.47
Ours w/o GDA	30.00 \pm 4.32	20.00 \pm 2.94	65.67 \pm 3.30	66.33 \pm 4.50	71.67 \pm 3.86	78.00 \pm 3.74	88.00 \pm 1.63
Ours	43.67 \pm 4.99	14.00 \pm 2.45	78.67 \pm 2.36	84.67 \pm 3.40	87.67 \pm 0.47	90.33 \pm 2.05	93.33 \pm 0.47

Table 5: Comparisons between our method and baselines on the entropy of the number of recommendations between jobs. Results that indicate the highest values are shown in bold, and the second-highest values are underlined.


	Private Data	CareerBuilder2012	Synthetic 1	Synthetic 2	Synthetic 3	Synthetic 4	Synthetic 5
ApplyPredictor	2.11 \pm 0.10	0.08 \pm 0.00	0.37 \pm 0.04	0.00 \pm 0.00	0.00 \pm 0.00	0.00 \pm 0.00	0.00 \pm 0.00
MatchPredictor	1.17 \pm 0.12	0.00 \pm 0.00	0.62 \pm 0.11	0.00 \pm 0.00	0.11 \pm 0.08	0.08 \pm 0.00	1.30 \pm 0.16
LiJAR	<u>3.68</u> \pm 0.28	2.60 \pm 0.75	3.43 \pm 0.04	2.08 \pm 0.02	2.43 \pm 0.01	2.99 \pm 0.03	3.38 \pm 0.02
StableMatching	5.19 \pm 0.08	6.34 \pm 0.06	6.34 \pm 0.06	6.34 \pm 0.06	6.34 \pm 0.06	6.34 \pm 0.06	6.34 \pm 0.06
Ours w/o GNNs	0.83 \pm 0.10	2.93 \pm 0.47	2.11 \pm 0.55	2.41 \pm 0.24	3.21 \pm 0.33	3.49 \pm 0.17	5.11 \pm 0.07
Ours w/o GDA	2.52 \pm 0.42	2.49 \pm 0.06	3.14 \pm 0.20	3.32 \pm 0.65	4.12 \pm 0.19	4.37 \pm 0.18	<u>6.08</u> \pm 0.05
Ours	3.37 \pm 0.60	<u>3.08</u> \pm 0.44	<u>4.34</u> \pm 0.19	<u>4.30</u> \pm 0.39	<u>5.29</u> \pm 0.08	<u>5.65</u> \pm 0.13	5.96 \pm 0.07

補足資料（可視化）

Maximize Applications



Redistribution (highest)



Ours

